

一种基于改进 CNN 的 ECG 房颤检测评分模型

黄君烈¹, 董昭荣², 饶浩³

1. 数学科学系 2. 航天航空学院 3. 集成电路学院, 清华大学, 北京 100084

【摘要】 随着智能医疗概念的普及, ECG 信号的实时分析和精确分类成为众多学者研究的热点。本文分别以 CWT 和带通滤波对原始 ECG 信号预处理, 用来排除原始信号中可能存在的各种噪声干扰。通过一维 CNN 自动提取去噪后 ECG 信号相关特征, 并将提取出的心电信号特征作为 LSTM 的输入, 最终通过集成模型实现心电信号的具体分类与起始点、终止点判断。该模型在测试集上的评分达到 $U_r = 0.94$ 、 $U_e = 1.03$ 、 $U = 1.97$ 。三位作者共同完成需求分析、模型设计、素材准备等工作, 其中黄俊烈、董昭荣主要负责模型架构优化、参数调整, 饶浩主要负责 ECG 信号去噪预处理及报告撰写。

【关键词】 ECG 信号分类, CNN, LSTM, 集成模型

1 引言

心电图^[1] (Electrocardiogram, ECG) 是利用心电图机从体表记录心脏每一心动周期所产生的电活动变化图像的技术, 常用于对各种心律失常、心室心房肥大、心肌梗死、心率异常、心肌缺血和心衰等疾病的检测。在一个心跳周期中, 心脏受到外界刺激后会有规律的持续收缩并产生电激动, 之后刺激消失后又会舒张, 在这个过程中, 会有大量的心肌细胞产生有规律的电位变化, 通过人体表面的电极记录电位变化曲线, 该曲线经过放大即可得到临床上 ECG。目前, 在传统的医学诊断过程中, 根据医生的经验对各类心电图进行分类识别是诊断患者是否患有心血管疾病的关键。然而, 人工识别 ECG 信号中的细微变化往往需要经验丰富的心电专家参与。专业的心电专家标耗时且成本昂贵, 而普通医生因经验不足可能影响心血管疾病患者的诊断和治疗。此外, 随着智能可穿戴设备 (如 Apple Watch, 智能手环) 的普及, ECG 信号采集变得更加便捷, 其使用门槛大幅度降低。若智能可穿戴设备能自动识别异常 ECG 信号, 则能

第一时间发起报警, 为急救与治疗争取黄金时间。因此, 如何采用计算机辅助算法实现对 ECG 信号的实时分析和精确分类一直是众多学者研究的热点。

ECG 信号识别主要包括 3 个重要阶段^[2], 分别是信号预处理、特征提取和自动识别。传统方法是依赖相关算法手动提取心电特征并进行分类, 如小波域特征分析^[3]、主成分分析^[4]和独立主成分分析^[5]等。然而, 这些方法提取的特征往往存在特征不够全面、计算繁琐的缺陷, 且因为心电信号对噪声相对敏感, 因此在后期进行信号分类时也容易限制分类的准确率。由于计算性能的大幅度提升, 采用深度学习技术^[6]实现心律失常自动检测逐渐成为一种主流。深度神经网络对噪声数据具有较好的鲁棒性和容错性, 且能够自适应地提取相关特征, 极大地提高了模型的分类准确率, 受到众多学者的关注, 被广泛应用于诸多分类问题中, 其中包括了对心电信号的智能分类。尽管现有深度学习模型相较非深度学习模型在性能上有大幅度的提升, 但仍有诸多问题需要解决: 如若采用二维灰度图像输入的卷积神经网络 (Convolutional Neural Network, CNN) 对心电数据特征的自动提取和分类^[7], 其二维卷积网络数据量庞大, 计算复杂不易训练。但若直接采用一维卷积处理 ECG 信号^[8], 虽然相比传统方法大大提高了准确率。但 CNN 本身存在小样本情况下容易过拟合的问题。

对此专家们也提出了许多改进方法^[9-10]。为了避免 CNN 的过拟合问题，一种常见的改进方法是将 CNN 与其他分类模型相结合。

针对现有方法的局限性，本文分别以连续小波变换 (Continuous Wavelet Transform, CWT) 和带通滤波对原始 ECG 信号预处理，用来排除原始信号中可能存在的各种噪声干扰；其次，通过一维 CNN 强大的学习和表征能力，自动提取 ECG 信号相关特征，并将提取出的心电信号特征作为长短期记忆 (Long Short-Term Memory, LSTM) 的输入最终实现心电信号的具体分类与起始点、终止点判断。最后，结合数据集进行模型性能的测试，通过固定评分标准进行对比实验，结果表明：相比现有方法，该方法进一步提高了分类准确率和找点准确。

2 实验设计

2.1 信号预处理

一个完整的心拍主要由 P 波、QRS 波群、T 波、PR 波段以及 ST 波段构成，不同波段分别反映了兴奋传导至心脏各部位的具体变化情况。PR 间期和 QT 间期可以传递心电信号非常重要的生理信息，是心电信号中非常重要的特征。一个完整的心电波形如图1所示：




图 1 完整心电信号波形

心电信号是一种微弱的生物电信号，其具有以下特征：

- (1) 微弱性：心电信号的幅值在 $10\mu\text{V}\sim 5\text{mV}$ 范围，是低幅值信号；
- (2) 不稳定性：心电信号在不断地变化且容易受到环境干扰，覆盖大量噪声，导致心电信号的很多有价值信息被淹没，很难检测，且不同个体

在不同时刻下的心电图都是不同的，即使同一个体在不同生理状态下波形也可能不同；

- (3) 能量集中性：心电信号的频率范围主要在 $0.05\text{Hz}\sim 100\text{Hz}$ 内，主要能量集中分布在 $0.5\text{Hz}\sim 40\text{Hz}$ 。

正是由于心电信号具有上述特性，其在采集过程中容易受到以下干扰，从而产生如图2所示带噪声的 ECG 信号波形：

- (1) 基线漂移：属于低频干扰，频率分布在 $0.15\text{Hz}\sim 0.3\text{Hz}$ 内，由于电极位置的滑动变化或者人体的呼吸运动造成心电信号随时间缓慢变化而偏离正常基线位置产生基线漂移，幅度和频率都会时刻变化着。心电信号中的 PR 波段和 ST 波段非常容易受到影响产生失真；
- (2) 工频干扰：由采集心电信号的设备周身的供电环境引起的电磁干扰，幅值低，噪声频率为 50Hz 左右，其波形很像一个正弦信号，该噪声常常会淹没有用的心电信号，也会影响 P 波和 T 波的检测；
- (3) 肌电干扰：心电信号在采集过程中贴片电极受到肌肉刺激引起的高频干扰，其频率变化范围在 $0.5\text{Hz}\sim 2000\text{Hz}$ 之间，能量集中范围在 $30\text{Hz}\sim 300\text{Hz}$ 之间，振幅一般不超过 1mV ，同时还具有随机性等特点，类似零均值的高斯白噪声^[11]，对心电信号整体特征干扰较大，去除较难，在心电图中表现为比较密集的参差不齐的“毛刺”，并与有用心电信号重合，从而可能导致有用心电信号的细微变化被忽视。由于心电信号的绝大部分频率集中在 $0.5\text{Hz}\sim 40\text{Hz}$ 之间， 40Hz 之后的频率分量可以近似看作“纯粹的”肌电干扰。




图 2 带噪声的 ECG 信号波形

为了提高 ECG 信号分类的准确度, 需要对信号进行预处理, 去除噪声。国内外研究学者针对去噪方面做了很多研究, 主要的去噪手段有经典的数字滤波器和基于 CWT 的阈值去噪等。经典的数字滤波器根据频率范围的不同对噪声进行去噪: 对于基线漂移使用高通滤波器去噪、对于肌电干扰使用低通滤波器去噪、对于工频干扰使用带通滤波器去噪。近年来, CWT 技术的快速发展催生出了一系列基于小波阈值去噪技术。该类技术是根据信号和噪声的频率在不同尺度上的分布, 先对信号进行 CWT, 再根据阈值对各层小波系数进行处理, 最后通过重构信号实现去噪, 其处理流程如图3所示:




图3 CWT 处理流程

由于 ECG 信号在小波域中有效信号所产生的小波系数模值往往较大, 而肌电干扰的特性类似于高斯白噪声, 在时间域上并不连续, 因此噪声所产生的小波系数其模值较小^[12], 根据这一特点, 只要对小波分解后的系数设置阈值, 即可通过适当的方法将阈值内的噪声去除。小波阈值去噪技术对于非平稳信号具有优秀的处理效果, 与传统处理方法相比有显著的优越性, 因而本文采用 CWT 阈值法对 ECG 信号进行预处理。

2.1.1 硬阈值函数

硬阈值函数的去噪原理是: 对阈值内的信号的值直接置零, 而对阈值外的信号的值进行保留。硬阈值函数的去噪原理如式(1)所示:

$$W_{\lambda} = \begin{cases} w & |w| \geq \lambda \\ 0, & else \end{cases} \quad (1)$$

式(1)中 w 表示原信号, λ 表示阈值, w_{λ} 表示去噪后的信号。通过式(1)可以看出, 去噪后信号保留了阈值以外信号的原始信息, 具有较好的保真性, 但 $w = \lambda$ 在处不连续, 因此去噪后的信号会

产生大量震荡点, 会对信号的后续分析造成影响。

2.1.2 软阈值函数

软阈值函数的去噪原理与硬阈值函数的原理类似, 同样对阈值内信号的值直接置零, 但对于阈值外的信号处理方式与硬阈值函数不同。当信号的值大于零时, 去噪后信号的值等于原信号的值减去阈值, 而当信号小于零时, 去噪后信号的值等于原信号加上阈值。软阈值函数的去噪原理如式(2)所示:

$$W_{\lambda} = \begin{cases} \text{sgn}(w)(|w| - \lambda) & |w| \geq \lambda \\ 0, & else \end{cases} \quad (2)$$

式(2)中 w 表示原信号, λ 表示阈值, w_{λ} 表示去噪后的信号。由式(2)可以看出, 软阈值函数解决了硬阈值函数在处不连续的缺点, 但是会对信号进行“压缩”, 使去噪后的信号与原信号之间存在恒定偏差, 造成信号失真。

2.1.3 自定义阈值函数

通过对软、硬阈值函数的分析可知, 它们都具有各自的优点, 但同时也具有不可忽视的缺点, 因此, 本文采用改进的自定义阈值函数。改进的阈值函数需遵循以下三个构建原则:

- (1) 阈值函数是连续函数, 去噪时不会产生断点;
- (2) 去噪前后阈值外信号的值相近, 即失真小;
- (3) 保留软、硬阈值函数的良好特征。

因而本文采用的阈值函数^[13]如式(3)所示:

$$W_{\lambda} = \begin{cases} \text{sgn}(w)(|w| - \frac{p\lambda}{p+(e^{q(|w|-\lambda)}-1)}) & |w| \geq \lambda \\ 0, & else \end{cases} \quad (3)$$

式(3)中 w 表示原信号, λ 表示阈值, w_{λ} 表示去噪后的信号。由式(3)可以看出, 当 $w \rightarrow \lambda$ 时 $w_{\lambda} \rightarrow 0$ 软阈值函数解决了硬阈值函数在阈值 λ 处不连续的缺点。当 $w \rightarrow \infty$ 时 $\frac{aw_{\lambda}}{w} \rightarrow 1$ 说明阈值函数曲线的渐近线为 $w_{\lambda} = w$, 解决了软阈值函数恒定偏差问题。为达到最佳滤波效果, 取自定义阈值函数参数 $p = 0.5$ 和 $q = 10$ 。

本文选 db5 小波基进行 7 层小波分解, 分解后各层波形如图4所示。cd1 层的细节分量的能量

与原始信号的高频干扰保持一致。表明 cD1 层是高频噪声（工频干扰以及肌电噪声）集中的主要地方。因此需要滤除 cD1 层细节分量即将其置 0。同理为去除基线漂移，滤除 cA7 层细节分量即将其置 0。然后，将处理后的信号分解得到的 2~7 层小波系数通过自定义阈值公式过滤。




图 4 小波变换分层波形

2.2 模型设计

2.2.1 分类模型设计

模型设计的主要思路是将 ECG 信号按照固定窗口（Window）、固定步长（Step）切片后处理。将两路 ECG 信号片段后分别经过两个投票网络，如图5所示。将两路输出投票后的标签进行比较判决，得到该 ECG 片段的标签（0 为正常片段、1 为房颤片段）。再根据根据房颤片段阈值（Segment Threshold, ST）即带有房颤标签的 ECG 片段数占 ECG 片段总数的比例，判断整个 ECG 信号的类别（0 为非房颤、1 为持续性房颤、2 为间歇性房颤）。




图 5 ECG 片段分类模型结构

为实现去噪后的 ECG 信号进行特征的提取和分类，本文参考样例模型^[14]以 CNN 为基础，构造集成模型。CNN 是目前应用最广泛的人工神经网络模型之一。与其他分类模型相比，CNN 特有的局部感知和权值共享操作使模型参数大幅减少，极大地提高了模型的训练效率，使得 CNN 模型可以更轻松地处理高维数据^[15]。但 CNN 并不完全适用于时间序列学习与处理，它需要各种辅助性处理。相比之下，RNN（如 LSTM）更合适对时间序列敏感的问题和任务。基于此，本文尝试结合 CNN 与 LSTM 构造混合模型，以期获得比单一模型更出色的训练结果。如图6所示，每个投票网络都是由 5 个 CNN + LSTM 网络（CNN LSTM Net）集成。每个 CNN + LSTM 网络由 5 个 CNN 单元（CNN Block）、1 个 LSTM 网络和 1 个分类层（MLP）构成。每个 CNN + LSTM 网络内部根据房颤成分阈值（Factor Threshold, FT）即房颤成分占房颤片段长度的比例，输出单个 CNN + LSTM 网络 ECG 片段标签所有输出 CNN + LSTM 网络输出结果进行投票，得到投票后的 ECG 片段标签。

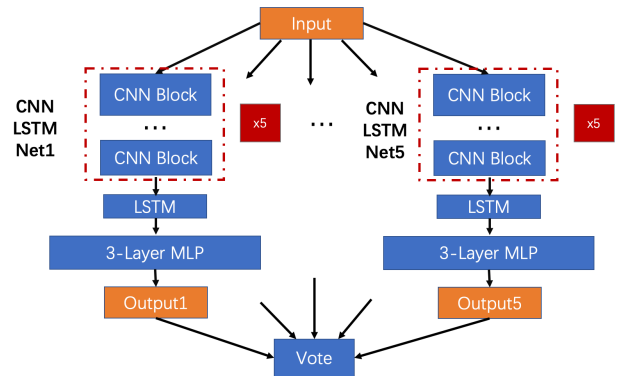


图 6 ECG 片段投票模型结构

每个 CNN 单元由引入残差的卷积层、CAM 单元、SE 单元和 ReLu 激活层组成，其结构如图7所示。CAM 单元和 SE 单元内部通过池化函数减少

模型特征参数,降低模型运算的计算量。ReLU 函数作为激活函数用以提高模型的整体性能。为防止出现过拟合现象, CAM 单元和 SE 单元内部又会进行池化卷积操作。

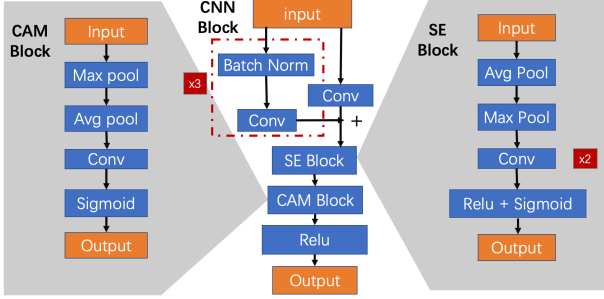


图 7 CNN 单元结构

2.2.2 找点模型设计

基于上述模型的训练结果,对于间歇性房颤片段利用相邻步长间隔但不同标签的两个 ECG 片段的中点确定房颤起始点或终止点。在找到一对起始点和终止点后,若两点间数据点数量不少于窗口大小,则该片段被判断为房颤片段(此规则仅对初始结束点有效)。以窗口大小 1000、步长 100 情况下寻找房颤起点为例,如图8所示。寻找相邻步长间隔下 ECG 片段,其中前一个 ECG 片段标签为 0,后一个 ECG 片段标签为 1。可将标签为 0 的 ECG 片段的中点作为起始点。同理,利用相邻步长间隔标签为 1 和 0 的两个 ECG 片段可确定房颤终止点。




图 8 寻找起始点

2.3 模型评价

根据模型对于各种类型完整 ECG 信号的分类结果: 正常 (Non-AF rhythm, N)、持续性房颤 (Persistent AF rhythm, AF_f) 和阵发性房颤 (Paroxysmal AF rhythm, AF_p), 按照评分矩阵 (图9) 得到分类评分 U_r 。

	Prediction		
	N	AF _f	AF _p
Answer	N	+1	-1
	AF _f	-2	+1
	AF _p	-1	0

图 9 分类评分矩阵

根据跟定脚本按照找点评分图 (图10) 得到找点评分 U_e 。




图 10 找点评分尺度

进一步根据式(4)得到综合得分 U 。

$$U = U_r + U_e \quad (4)$$

3 实验结果与分析

本文实验环境基于 Python 3.6, 主要依赖包有 Pytorch、Wfdb、Scipy、Pywt、Numpy 等。

3.1 信号预处理

本文以自定义小波变换 (图中 Wavelet) 进行信号预处理, 以通频带在 0.1Hz~45Hz 的五阶带通滤波器 (图中 Butter) 处理结果和原始信号 (图中 Original) 作为对比。通过对信号处理后的频谱图 (图11) 和波形效果图 (图12) 分析可知:

- (1) 带通滤波处理: 完全滤除了 0.1Hz~45Hz 以外的频率分量, 这不可避免的造成通道外有用频率分量的损失。此外, 其未能去除基线漂移以及有效压制通带内肌电噪声;
- (2) 自定义小波变换处理: 超低频部分滤除基线漂移, 1Hz~40Hz 内有效压制肌电噪声, 40Hz~80Hz 内有效压制肌电噪声工频噪声和肌电噪声且不至于频段内所有频率分量, 高频信号全部滤除;

(3) 综合波形图可以发现，自定义小波变换处理后的效果明显好于原始信号及带通滤波处理后的效果。




图 11 ECG 信号处理后频谱对比




图 12 ECG 信号处理后波形对比

3.2 模型调参与测试

基础模型参数：步长为 200、窗宽为 1000，正常 SF 为 0.95、持续性房颤 SF 为 0.9、信号滤波器为带通滤波器。调整步长，固定其他参数得到表1。

表 1 步长调整

步长	U_r	U_e	U
100	0.9088	1.0158	1.9246
200	0.8965	0.8825	1.7789

表 2 正常 SF 调整

正常 SF	U_r	U_e	U
0.95	0.9088	1.0158	1.9246
0.99	0.9193	1.0298	1.9491

由表1可知步长 100 时，模型性能较好。因而修正模型参数：步长为 100、窗宽为 1000，正常 SF

表 3 窗宽调整

窗宽	U_r	U_e	U
400	0.8491	0.7649	1.6140
600	0.8982	0.9470	1.8452
1000	0.9211	1.0202	1.9412
1400	0.9123	1.0246	1.9368

为 0.95、持续性房颤 SF 为 0.9、信号滤波器为带通滤波器。调整正常 SF，固定其他参数得到表2。

表 4 信号滤波器调整

滤波器	U_r	U_e	U
带通滤波器	0.9211	1.0202	1.9412
小波滤波器	0.9281	0.8400	1.7681

表 5 模型对比

滤波器	集合	U_r	U_e	U
带通滤波器	测试集	0.9211	1.0202	1.9412
集成模型	测试集	0.9351	1.0343	1.9694
集成模型	训练集	0.9355	1.0858	2.0213

由表2可知步长 100 时，模型性能较好。因而修正模型参数：步长为 100、窗宽为 1000，正常 SF 为 0.95、持续性房颤 SF 为 0.9、信号滤波器为带通滤波器。调整窗宽，固定其他参数得到表4。

由表4可知道窗宽 1000 时，模型性能较好。因而保持模型参数：步长为 100、窗宽为 1000，正常 SF 为 0.95、持续性房颤 SF 为 0.9、信号滤波器为带通滤波器。切换信号滤波器，固定其他参数得到表5。

由表4可知尽管使用小波滤波器的 U_e 和 U 不高，但其 U_r 达到最大。因而考虑将使用小波滤波器的模型和使用带通滤波器的模型集成使用，训练集和测试集结果如表5、表6、表7所示。

3.2.1 提升与问题

通过对比发现，最终模型性能 (U_r 、 U_e 和 U) 相较于初始模型均有明显提升。最终模型对于正常 ECG 信号和持续性房颤 ECG 信号的分类已经达到较高水平，与之相对的间歇性房颤 ECG 片段仍有一定数量被错分。间歇性房颤 ECG 信号被错分为正常 ECG 信号，说明模型未能识别特定的房颤 ECG 片段，可能是因为该类房颤 ECG 片段持续

表 6 集成模型训练集分类结果

类别	N	AFf	AFp	总数
N	575	0	1	576
AFf	0	379	1	380
AFp	29	13	141	183

表 7 集成模型测试集分类结果

类别	N	AFf	AFp	总数
N	144	0	1	145
AFf	1	93	1	95
AFp	5	3	37	45

时间较短小于一半窗宽。间歇性房颤 ECG 信号被错分为持续性房颤 ECG 信号, 说明模型未能识别特定的正常 ECG 片段, 可能是因为该类正常 ECG 片段持续时间较短小于步长。此外, 由于计算资源的限制, 参数遍历、迭代次数不太充分, 相应参数未必是全局最优。

4 结论

本文分别通过将 CNN 和 LSTM 相结合, 并用小波滤波器和带通滤波器分别对原始 ECG 信号预处理构造集成模型, 入最终实现心电信号的具体分类与起始点、终止点判断。根据特定评分方法, 该模型在测试集上的评分达到 $U_r = 0.94$ 、 $U_e = 1.03$ 、 $U = 1.97$ 。该模型仍可以通过进一步优化参数, 提高间歇性房颤分类准确度以及找点准确度。

参考文献

- [1] XU G. Iot-assisted ecg monitoring framework with secure data transmission for health care applications[J]. IEEE Access, 2020, PP(99): 1-1.
- [2] 张丹, 何志涛, 陈永毅, 等. 基于 CNN 和 ET 的智能 ECG 识别方法[J]. 浙江工业大学学报, 2021, 49(6): 6.
- [3] 蒋腾, 胡涛, 祝民鹏, 等. 基于连续小波变换的多数据心率提取方法[J]. 现代雷达, 2019, 41(5): 5.
- [4] LI H, LIANG H, MIAO C, et al. Novel ecg signal classification based on kica nonlinear feature extraction[J]. Circuits Systems and Signal Processing, 2016, 35(4): 1187-1197.
- [5] CHANG P, WANG K, WANG P. Quality relevant over-complete independent component analysis based monitoring for non-linear and non-gaussian batch process - sciencedirect[J]. Chemometrics and Intelligent Laboratory Systems, 205.
- [6] MIN S, BYUNGHAN L, SUNGROH Y. Deep learning in bioinformatics[J]. Briefings in Bioinformatics, 2017(5): 851.

- [7] 查雪帆, 杨丰, 吴侯南, 等. 结合迁移学习与深度卷积网络的心电分类研究[J]. 中国医学物理学杂志, 2018, 35(11): 6.
- [8] URAAB C, SHU L, YH A, et al. A deep convolutional neural network model to classify heartbeats[J]. Computers in Biology and Medicine, 2017, 89: 389-396.
- [9] A U B B, A M T, A O Y, et al. Classification of myocardial infarction with multi-lead ecg signals and deep cnn[J]. Pattern Recognition Letters, 2019, 122: 23-30.
- [10] 孙波, 杨磊, 郭秀梅, 等. 基于 CNN 和 SVM 混合模型的心电信号识别方法[J]. 山东农业大学学报: 自然科学版, 2020, 51(2): 6.
- [11] 余娇, 罗泽峰, 崔文超. ECG 信号去噪分析与评估[J]. 信息通信, 2018(3): 5.
- [12] 徐阳, 罗明璋, 李涛. 基于 CEEMDAN 和小波阈值的 ECG 去噪算法研究[J]. 现代电子技术, 2018, 41(7): 5.
- [13] 杨承金, 聂春燕, 王慧宇, 等. 基于小波改进阈值的肌电干扰降噪研究与效果评估[J]. 电子测量技术, 2021: <https://kns.cnki.net/kcms/detail/11.2175.TN.20211207.2245.042.html>.
- [14] RUI Y. Python example code for the 4th china physiological signal challenge 2021[J]. 2021: https://github.com/YuRui8879/CPSC2021_python.
- [15] SHAKER A M, TANTAWI M, SHEDEED H A, et al. Generalization of convolutional neural networks for ecg classification using generative adversarial networks[J]. IEEE Access, 2020, 8: 35592-35605.